ĐỀ CƯƠNG LUẬN VĂN

DỰ ĐOÁN HIỆU ỨNG ĐỘT BIẾN DEGRON Ở MỨC RESIDUE VÀ XÂY DỰNG CÔNG CỤ HỖ TRỢ PHÂN TÍCH

Sinh viên thực hiện: Nguyễn Thanh Trọng — MSSV: B2305615
Giáo viên hướng dẫn 1: TS. Hồ Quang Thái — MSCB: [Bổ sung]
Giáo viên hướng dẫn 2: [Bổ sung nếu có] — MSCB: [Bổ sung nếu có]

I. MỞ ĐẦU

1. Lý do chọn đề tài

Lượng protein trong tế bào chịu ảnh hưởng của cả quá trình tổng hợp và phân hủy. Trong hệ ubiquitin–proteasome, degron là tín hiệu liên quan đến việc nhận diện protein để phân hủy. Một thay đổi amino acid tại degron có thể làm thay đổi hoạt tính tín hiệu này. Vì vậy, xác định ảnh hưởng của từng phép thay thế có ý nghĩa đối với việc lựa chọn đột biến để kiểm chứng chức năng protein [1, 2].

Điểm hoạt tính của cả đoạn peptide chưa trực tiếp trả lời câu hỏi: thay amino acid nào, tại vị trí nào, sẽ làm tín hiệu degron mạnh lên hay yếu đi? Đo toàn bộ các phép thay thế bằng thực nghiệm cần nhiều nguồn lực. Mô hình dự đoán có thể hỗ trợ thu hẹp danh sách đột biến ưu tiên, với điều kiện được đánh giá trên nhãn phù hợp và kiểm soát sự tương đồng giữa dữ liệu huấn luyện và kiểm tra.

Zhang và cộng sự cung cấp dữ liệu đột biến quét và bão hòa làm cơ sở xây dựng nhãn thực nghiệm [1]. PAP và Degformer cung cấp các phương pháp đối chứng; trong đó Degformer đã hỗ trợ mô phỏng đột biến và xuất ma trận vị trí × amino acid [2, 3]. Do đó, đóng góp cần được kiểm chứng bằng hiệu quả dự đoán, độ ổn định và thiết kế đánh giá, thay vì chỉ dựa vào việc tạo ma trận hoặc xây dựng giao diện mới.

Khảo sát thực nghiệm nội bộ bước đầu cho thấy mô hình ridge có thể vượt đối chứng chênh lệch điểm PAP trên bộ bão hòa, nhưng chưa xác lập được lợi ích ổn định của các thành phần kiến trúc phức tạp hơn [8]. Đề tài tiếp tục nghiên cứu vai trò của lượng nhãn, biểu diễn trình tự và học chuyển tiếp; đồng thời xây dựng công cụ giúp truy xuất kết quả cùng nguồn gốc và giới hạn áp dụng.

2. Mục tiêu nghiên cứu

Mục tiêu chung: Nghiên cứu phương pháp dự đoán hiệu ứng của các phép thay thế amino acid trong degron từ dữ liệu thực nghiệm, đánh giá khả năng tổng quát hóa theo cụm protein và xây dựng công cụ hỗ trợ phân tích, ưu tiên đột biến.

Mục tiêu cụ thể:

- Xây dựng pipeline chuẩn hóa dữ liệu, ánh xạ tọa độ và tạo nhãn hiệu ứng đột biến có thể tái lập; giữ riêng các nguồn và điều kiện đo.

- Thiết lập các đối chứng thành phần amino acid, ridge, chênh lệch điểm PAP và kiến trúc Degformer trong những điều kiện so sánh được công bố rõ.
- Kiểm tra giả thuyết học biểu diễn từ nhãn mức peptide rồi tinh chỉnh trên nhãn đột biến có cải thiện dự đoán so với học trực tiếp hay không; khảo sát đường cong học trước khi lựa chọn mô hình.
- Đánh giá hiệu quả, độ ổn định qua nhiều seed, sai số và đóng góp từng thành phần bằng thí nghiệm loại bỏ thành phần.
- Xây dựng nguyên mẫu phần mềm nhập peptide, hiển thị ma trận hiệu ứng dự đoán, xếp hạng đột biến và xuất kết quả kèm thông tin mô hình.

3. Đối tượng và phạm vi nghiên cứu

Đối tượng: Các peptide degron, phép thay thế đơn amino acid, chỉ số ổn định protein trong phép đo reporter và mô hình dự đoán hiệu ứng đột biến ở mức residue. Residue là một amino acid tại một vị trí cụ thể của chuỗi protein; footprint trong đề tài là bản đồ các vị trí hoặc phép thay thế ảnh hưởng đến hoạt tính degron theo hệ đo.

Phạm vi:

- Nguồn nhãn chính là dữ liệu peptide người của Zhang 2023, gồm đột biến quét và bão hòa. Bộ bão hòa sau lọc hiện có 91 peptide, 89 cụm protein và 47.847 ô phép thay thế [8]. Đây là số mẫu sau xử lý của đề tài.
- Đầu vào chính là trình tự tham chiếu (WT), vị trí và amino acid thay thế. Đầu ra là hiệu ứng dự đoán ΔPSI; có thể tổng hợp thành ma trận $L \times 20$, với L là độ dài peptide thuộc miền mô hình hỗ trợ.
- Dữ liệu mức peptide của Voutsinos được xem xét cho học chuyển tiếp. Larsen chỉ phục vụ khảo sát chuyển miền ở mức tile khi điều kiện sử dụng được xác nhận; không được thay cho nhãn đột biến thực nghiệm [2, 4].
- Không đặt nhận diện E3 cụ thể làm nhiệm vụ chính. Chưa thực hiện thí nghiệm sinh học mới; kết quả phần mềm hỗ trợ hình thành giả thuyết, không suy ra quan hệ nhân quả gây bệnh hoặc hiệu quả điều trị.

II. CƠ SỞ LÝ THUYẾT

1. Degron và hệ ubiquitin–proteasome

- **Khái niệm và vai trò:** protein, amino acid, residue, degron, enzyme E3 ligase, ubiquitin và proteasome; quan hệ giữa tín hiệu degron và sự phân hủy có chọn lọc.
- **Bối cảnh sinh học:** hoạt tính của peptide tách rời có thể khác hoạt tính khi đoạn đó nằm trong protein nguyên vẹn; độ lộ bề mặt, cấu trúc và môi trường tế bào là những yếu tố cần cân nhắc.
- **Tài liệu tham khảo:** Zhang và cộng sự [1]; Voutsinos và cộng sự [2]; Larsen và cộng sự [4].

2. Đo hoạt tính degron và hiệu ứng đột biến

- **GPS và PSI:** Global Protein Stability profiling dùng reporter và phân loại tế bào theo tín hiệu huỳnh quang. Protein Stability Index (PSI) tóm tắt phân bố tín hiệu qua các bin. Trong dữ liệu Zhang, PSI thấp hơn tương ứng reporter kém bền hơn.
- **Định nghĩa hiệu ứng:** ΔPSI = PSI(mutant) − PSI(WT). Giá trị dương biểu thị reporter bền hơn theo phép đo; không tự chứng minh cơ chế nhận diện trực tiếp của E3.
- **Thiết kế đột biến:** scanning khảo sát phép thay thế quét tại các vị trí; saturation khảo sát nhiều amino acid thay thế tại từng vị trí. Các ô cùng peptide có liên hệ thống kê, không được coi là những mẫu độc lập hoàn toàn.
- **Nguồn nhiễu:** số đọc, khác biệt replicate và điều kiện đo. Pipeline phải mô tả cách tạo mốc WT, gộp replicate và xử lý giá trị thiếu. Mốc WT của bộ bão hòa lấy từ các ô đồng nghĩa trong cùng hệ đo; không lấy điều kiện BAG6 WT thay thế [8].
- **Tài liệu tham khảo:** Zhang và cộng sự [1], bộ dữ liệu Mendeley phiên bản 2 [6].

3. Học máy cho dự đoán hiệu ứng đột biến

- **Biểu diễn:** mã hóa amino acid tham chiếu và thay thế, thành phần peptide, cửa sổ ngữ cảnh quanh vị trí đột biến; xem xét biểu diễn học được từ dữ liệu mức peptide.
- **Mô hình:** hồi quy ridge làm đối chứng đơn giản; PAP dự đoán điểm cả peptide, từ đó tính ΔPAP = PAP(mutant) − PAP(WT); Degformer dùng transformer dự đoán PSI [2, 3]. Chiều điểm khi đánh giá phải thống nhất với nhãn đích.
- **Học chuyển tiếp:** tiền huấn luyện biểu diễn trên nhãn hoạt tính mức peptide rồi tinh chỉnh cho ΔPSI. Nhãn hai mức có ý nghĩa khác nhau nên cần đầu dự đoán hoặc phép biến đổi phù hợp; không đổi nhãn nhị phân motif thành ΔPSI.
- **Công cụ dự kiến:** Python, NumPy, pandas, scikit-learn, PyTorch và MMseqs2; chỉ chọn cấu hình đủ nguồn lực và ghi phiên bản khi thực nghiệm.
- **Tài liệu tham khảo:** PAP [2], Degformer [3], MetaDegron [5] để đối chiếu phạm vi dự đoán.

4. Đánh giá và khả năng tái lập

- Chia dữ liệu theo cụm protein tương đồng thay vì chia ngẫu nhiên từng ô. Quy ước cov80 hiện dùng là phân cụm MMseqs2 với ngưỡng đồng nhất 30% và độ phủ 80%; kiểm độ nhạy bằng độ phủ 50% khi phù hợp.
- Dùng tập validation theo cụm bên trong mỗi fold huấn luyện để chọn siêu tham số; mọi chuẩn hóa, chọn đặc trưng và tiền huấn luyện đều phải loại cụm kiểm tra ngoài.
- Chỉ số chính là AUROC mức ô, tính riêng trên peptide đủ hai lớp rồi lấy trung bình. Nhãn nhị phân, ngưỡng và chiều hiệu ứng phải được cố định trong protocol trước so sánh. Bổ sung tương quan Spearman hoặc MAE cho ΔPSI liên tục và phân tích footprint khi đủ nhãn.
- So sánh ghép cặp trên cùng peptide; bootstrap theo cụm protein để ước lượng khoảng tin cậy. Báo kết quả từng seed bên cạnh kết quả tổng hợp và phân biệt benchmark phát triển với kiểm chứng độc lập.

III. PHƯƠNG PHÁP NGHIÊN CỨU

1. Phương pháp tiếp cận

Đề tài kết hợp khảo sát tài liệu, nghiên cứu thực nghiệm có đối chứng và phát triển nguyên mẫu phần mềm. Câu hỏi nghiên cứu chính là: với dữ liệu đột biến có hạn, học biểu diễn từ nhãn mức peptide có tạo ra lợi ích dự đoán ổn định so với ridge và ΔPAP khi kiểm soát tương đồng protein hay không?

Trước hết, khảo sát đường cong học theo số cụm huấn luyện để kiểm tra giả thuyết thiếu nhãn. Sau đó, so cùng một bộ mã hóa ở hai chế độ khởi tạo ngẫu nhiên và tiền huấn luyện, dùng chung fold, ngân sách nhãn đột biến và quy trình chọn siêu tham số. Các nhánh mô hình là phương án dự kiến, được giữ lại theo bằng chứng; đề cương không mặc định một kiến trúc mới sẽ thắng đối chứng.

Thiết kế dự kiến kế thừa 5 outer fold theo cụm cov80, validation bên trong, seed 17/29/43 và 5.000 lần bootstrap theo cụm. Mỗi nguồn tiền huấn luyện phải được kiểm chồng cụm với outer-test trước khi học. Các checkpoint có sẵn chỉ đưa vào bảng so sánh tổng quát hóa khi đã xác minh điều kiện dữ liệu; huấn luyện lại kiến trúc Degformer cùng ngân sách nhãn phải được ghi riêng với việc tái lập đầy đủ chế độ huấn luyện của tác giả.

Bằng chứng phát triển hiện có ghi nhận AUROC macro 0,8082 của ridge và 0,7693 của ΔPAP trên cùng bộ bão hòa [8]. Kết quả này chưa chứng minh tính mới kiến trúc. Các thử nghiệm tương tác và huấn luyện lại kiến trúc Degformer với ngân sách nhãn nhỏ cũng chưa cho lợi ích so với ridge [9]. Dữ liệu này định hướng giả thuyết tiếp theo, không thay thế một phép kiểm chứng xác nhận cuối cùng.

Đối với ứng viên mới, chỉ xem là có bằng chứng cải thiện khi chênh lệch ghép cặp với đối chứng chính có khoảng tin cậy dương và kết quả nhất quán qua các seed theo tiêu chí chốt trước. Nếu chưa đạt, báo cáo kết quả âm, giới hạn và nguyên mẫu sử dụng mô hình đối chứng tốt nhất; không tự coi mục tiêu đóng góp phương pháp đã hoàn thành.

2. Quy trình thực hiện

STT	Nội dung	Kết quả
1	Nghiên cứu sinh học degron, khảo sát PAP, Degformer, MetaDegron và nguồn nhãn	Tổng quan tài liệu; bảng so sánh bài toán, dữ liệu và giới hạn
2	Kiểm dữ liệu, tái tính PSI, ánh xạ tọa độ, phân cụm và thiết kế đánh giá	Bảng nhãn; sổ nguồn gốc; danh sách fold; protocol và đối chứng
3	Đo đường cong học; thiết kế, huấn luyện mô hình và ablation; xây dựng phần mềm	Runner tái lập; mô hình ứng viên; API, giao diện và chức năng xuất kết quả
4	Kiểm thử phần mềm và kiểm chéo thực nghiệm	Ca kiểm thử; đối chiếu điểm giao diện với runner; báo cáo rò rỉ, lỗi và kết quả từng seed
5	Đánh giá, phân tích sai số, viết báo cáo và hoàn thiện luận văn	Bảng so sánh có khoảng tin cậy; báo cáo đóng góp, giới hạn; mã nguồn và hướng dẫn

Tiến độ theo tuần và mốc nộp sẽ bổ sung sau khi có lịch học phần và thống nhất phạm vi với giảng viên hướng dẫn.

IV. ỨNG DỤNG THỰC TẾ VÀ NGUỒN DỮ LIỆU

1. Ứng dụng thực tế

- Hỗ trợ người nghiên cứu lựa chọn vị trí và amino acid thay thế để làm thí nghiệm tiếp theo, kèm đột biến đối chứng.
- Trực quan hóa ma trận hiệu ứng, đối chiếu dự đoán với ô thực nghiệm đã có và truy xuất nguồn dữ liệu, phiên bản mô hình.
- Hỗ trợ giảng dạy và khảo sát mối liên hệ giữa trình tự peptide và tín hiệu phân hủy. Kết quả chỉ có ý nghĩa trong phạm vi hệ đo và miền dữ liệu được mô tả.

Luồng phần mềm dự kiến: nhập peptide hợp lệ → sinh các phép thay thế → tính điểm bằng mô hình đã cố định → hiển thị ma trận và bảng xếp hạng → xuất CSV/JSON cùng provenance. Trường hợp thiếu dữ liệu, sai tọa độ hoặc nằm ngoài miền hỗ trợ phải được thể hiện rõ; không chuyển điểm chưa hiệu chuẩn thành xác suất bệnh.

2. Nguồn dữ liệu thử nghiệm

Nguồn dữ liệu	Mô tả và vai trò	Link
Zhang 2023 — Mendeley Data v2	Nhãn chính: count/GPS, đột biến quét và bão hòa; dữ liệu CC BY 4.0	Mendeley v2
Zhang — GEO GSE240610	Đối chiếu nguồn peptidome; các bảng dự đoán sẵn không thay thế nhãn đo	GSE240610
Voutsinos/PAP	Tile bào tương và mô hình PAP; đối chứng và nguồn nhãn mức peptide cho học chuyển tiếp	Kho tác giả
Larsen — transcription factors	Tile trong bối cảnh nhân; khảo sát chuyển miền ở mức tile nếu quyền sử dụng được chốt	Kho tác giả
UniProtKB/Swiss-Prot	Trình tự, accession và tọa độ phục vụ ánh xạ và phân cụm protein	UniProt
MaveDB và ClinVar, bổ trợ	Khảo sát ca nghiên cứu nếu endpoint phù hợp; không gộp điểm abundance hay nhãn bệnh vào ΔPSI	MaveDB; ClinVar

Mỗi nguồn được ghim phiên bản hoặc ngày tải, checksum và điều kiện sử dụng. Nhãn khác assay được giữ riêng. MetaDegron chỉ dùng khảo sát/truy nguồn trong phạm vi hiện tại; việc nhập nhãn vào huấn luyện hoặc công khai còn phụ thuộc quyền sử dụng và thẩm định nguồn [10].

V. CÁC DỰ ÁN LIÊN QUAN

Dự án	Mô tả và quan hệ với đề tài	Link
PAP	Dự đoán hoạt tính cả peptide; chênh điểm mutant–WT tạo đối chứng ΔPAP	PAP và dữ liệu
Degformer	Transformer dự đoán PSI; đã hỗ trợ đột biến quét/bão hòa và ma trận 28 × 20; đối chứng gần nhất cần kiểm soát overlap	Degformer
MetaDegron	Dự đoán degron ở mức motif/đoạn; dùng so sánh phạm vi chức năng, loại nhãn và nguồn gốc dữ liệu	Bài báo
DEGRONOPEDIA	Công cụ phân tích degron; đối chiếu chức năng tra cứu và cách trình bày kết quả	Tài liệu
DegronMD	Tài nguyên degron và biến thể; đối chiếu thông tin chú giải, không mặc định dữ liệu dự đoán là nhãn thật	Bài báo

Ma trận thay thế, xử lý theo lô hoặc giao diện web không được dùng riêng để khẳng định tính mới. Điểm khác biệt dự kiến nằm ở bằng chứng đánh giá theo cụm, kiểm soát nguồn nhãn và quy trình hỗ trợ ưu tiên đột biến có thể tái tính.

VI. DỰ KIẾN KẾT QUẢ VÀ ĐÓNG GÓP

- **Dữ liệu và đánh giá:** pipeline tạo nhãn có nguồn gốc rõ ràng, bộ chia theo cụm và runner tái lập; báo cáo riêng độ chồng lặp, điều kiện assay và hạn chế của các đối chứng.
- **Kết quả nghiên cứu:** bằng chứng về ảnh hưởng của lượng nhãn và hiệu quả học chuyển tiếp đối với dự đoán ΔPSI. Nếu có cải thiện ổn định, xác định thành phần tạo lợi ích bằng ablation; nếu chưa có, báo cáo trung thực phạm vi thất bại và giới hạn kết luận.
- **Sản phẩm phần mềm:** nguyên mẫu nhập peptide, tạo ma trận dự đoán, xếp hạng phép thay thế, đối chiếu dữ liệu đo và xuất kết quả kèm phiên bản mô hình, nguồn dữ liệu, miền áp dụng.
- **Kiểm thử và tài liệu:** bộ ca kiểm thử đầu vào, tọa độ, chiều điểm và xuất dữ liệu; kết quả giao diện khớp runner trong sai số số học; tài liệu cài đặt, sử dụng và tái lập.
- **Luận văn:** tổng quan, thiết kế phương pháp, kết quả định lượng, phân tích sai số, giới hạn và hướng phát triển. Khả năng vượt đối chứng và tính mới kiến trúc là mục tiêu cần kiểm chứng, chưa phải kết quả đã đạt.

VII. TÀI LIỆU THAM KHẢO

Quản lý tài liệu bằng **Zotero hoặc Mendeley** theo yêu cầu của mẫu. Danh mục dưới đây là danh mục khởi đầu; các báo cáo nội bộ [8–10] dùng để truy xuất bằng chứng tiền đề, không thay thế công trình khoa học đã công bố.

1. Zhang, Z. và cộng sự (2023). *Elucidation of E3 ubiquitin ligase specificity through proteome-wide internal degron mapping*. Molecular Cell, 83, 3377–3392.e6. DOI: https://doi.org/10.1016/j.molcel.2023.08.022.

2. Voutsinos, V. và cộng sự (2026). *A near-complete map of human cytosolic degrons and their relevance for disease*. Science Advances. DOI: https://doi.org/10.1126/sciadv.adz3483.
3. Alpine2048. *Degformer: Transformer model for internal and C-terminal degron prediction*. Mã nguồn, commit 49ee52459967. GitHub.
4. Larsen, F. B. và cộng sự (2025). *Comprehensive degron mapping in human transcription factors*. bioRxiv, bản tiền ấn phẩm. DOI: https://doi.org/10.1101/2025.05.16.654404.
5. Zheng, M. và cộng sự (2024). *MetaDegron: multimodal feature-integrated protein language model for predicting E3 ligase targeted degrons*. Briefings in Bioinformatics, 25(6), bbae519. DOI: https://doi.org/10.1093/bib/bbae519.
6. Zhang và cộng sự (2023). Bộ dữ liệu đi kèm nghiên cứu degron, *Mendeley Data*, phiên bản 2. DOI: https://doi.org/10.17632/32h94v2yv2.2.
7. NCBI. *GEO Series GSE240610*. Trang dữ liệu.
8. Nguyễn Thanh Trọng (18/10/2026). *G2 — học trực tiếp trên ma trận bão hòa*. Báo cáo nội bộ; số mẫu và AUROC từ `research/g2-saturation-2026-10-18/results.json`; khoảng tin cậy ridge từ `audit.json`.
9. Nguyễn Thanh Trọng (18/10/2026). *G2 — mở rộng: ba câu hỏi còn mở của báo cáo bão hòa*. Báo cáo nội bộ; kết quả tại `research/g2-extension-2026-10-18/`.
10. Nguyễn Thanh Trọng (21/10/2026). *Phân tích MetaDegron và đối chiếu đề tài hiện tại*. Báo cáo nội bộ tại `research/metadegron-analysis-2026-10-21/`; phần đề xuất chưa phải quyết định thực hiện.